

# Αναγνώριση Προτύπων

## Ταξινόμηση

Τεχνητά νευρωνικά δίκτυα

**Ανδρέας Λ. Συμεωνίδης**

**Αν. Καθηγητής**

Τμήμα Ηλεκτρολόγων Μηχ/κών

&

Μηχ/κών Υπολογιστών, Α.Π.Θ.

Email: [asymeon@eng.auth.gr](mailto:asymeon@eng.auth.gr)



ARISTOTLE  
UNIVERSITY OF  
THESSALONIKI


# Διάρθρωση διάλεξης

- Τεχνητά νευρωνικά δίκτυα
- Perceptrons

# Τεχνητά Νευρωνικά Δίκτυα

- Γραμμικός διαχωρισμός
- Τεχνητά νευρωνικά δίκτυα
- Perceptrons – Μέθοδος Ελαχίστων Τετραγώνων


# Γραμμικά διαχωρίσιμα προβλήματα




# Όρια απόφασης

- Σε απλές περιπτώσεις χωρίζει τον χώρο των μεταβλητών ορίζοντας ένα υπερεπίπεδο που το διασχίζει.
- Γνωστό ως **όριο απόφασης**.
- **Συνάρτηση διαχωρισμού**: επιστρέφει διαφορετικές τιμές στις διαφορετικές πλευρές του υπερεπιπέδου.
- Κατά συνέπεια, επιλύει προβλήματα **γραμμικής ταξινόμησης**.

# Γραμμικοί ταξινομητές




- : Δηλώνει +1
- : Δηλώνει -1



$$f(x, w, b) = \text{sign}(w x + b)$$

# Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks - ANN)

$X_1$	$X_2$	$X_3$	$Y$
1	0	0	0
1	0	1	1
1	1	0	1
1	1	1	1
0	0	1	0
0	1	0	0
0	1	1	1
0	0	0	0




Η έξοδος  $Y$  είναι 1 εάν τουλάχιστον 2 από τις 3 εισόδους είναι ίσες με 1.

# Τεχνητά Νευρωνικά Δίκτυα - I

$X_1$	$X_2$	$X_3$	$Y$
1	0	0	0
1	0	1	1
1	1	0	1
1	1	1	1
0	0	1	0
0	1	0	0
0	1	1	1
0	0	0	0

Input nodes




$$Y = I(0.3X_1 + 0.3X_2 + 0.3X_3 - 0.4 > 0)$$

$$\text{όπου } I(z) = \begin{cases} 1 & \text{εάν } z \text{ αληθές} \\ 0 & \text{αλλιώς} \end{cases}$$



# Τεχνητά Νευρωνικά Δίκτυα - II

- Το μοντέλο είναι μια σύνθεση από συνδεδεμένους κόμβους και συνδέσμους με βάρη
- Ο κόμβος εξόδου αθροίζει κάθε μια από τις τιμές εισόδου του, ανάλογα με τα βάρη των συνδέσμων
- Σύγκριση του κόμβου εξόδου με ένα κατώφλι  $t$




Μοντέλο **Perceptron**


$$Y = I\left(\sum_i w_i X_i - t\right) \text{ ή}$$

$$Y = \text{sign}\left(\sum_i w_i X_i - t\right)$$

# Το υπερπίπεδο απόφασης του Perceptron



Γραμμικά διαχωρίσιμο



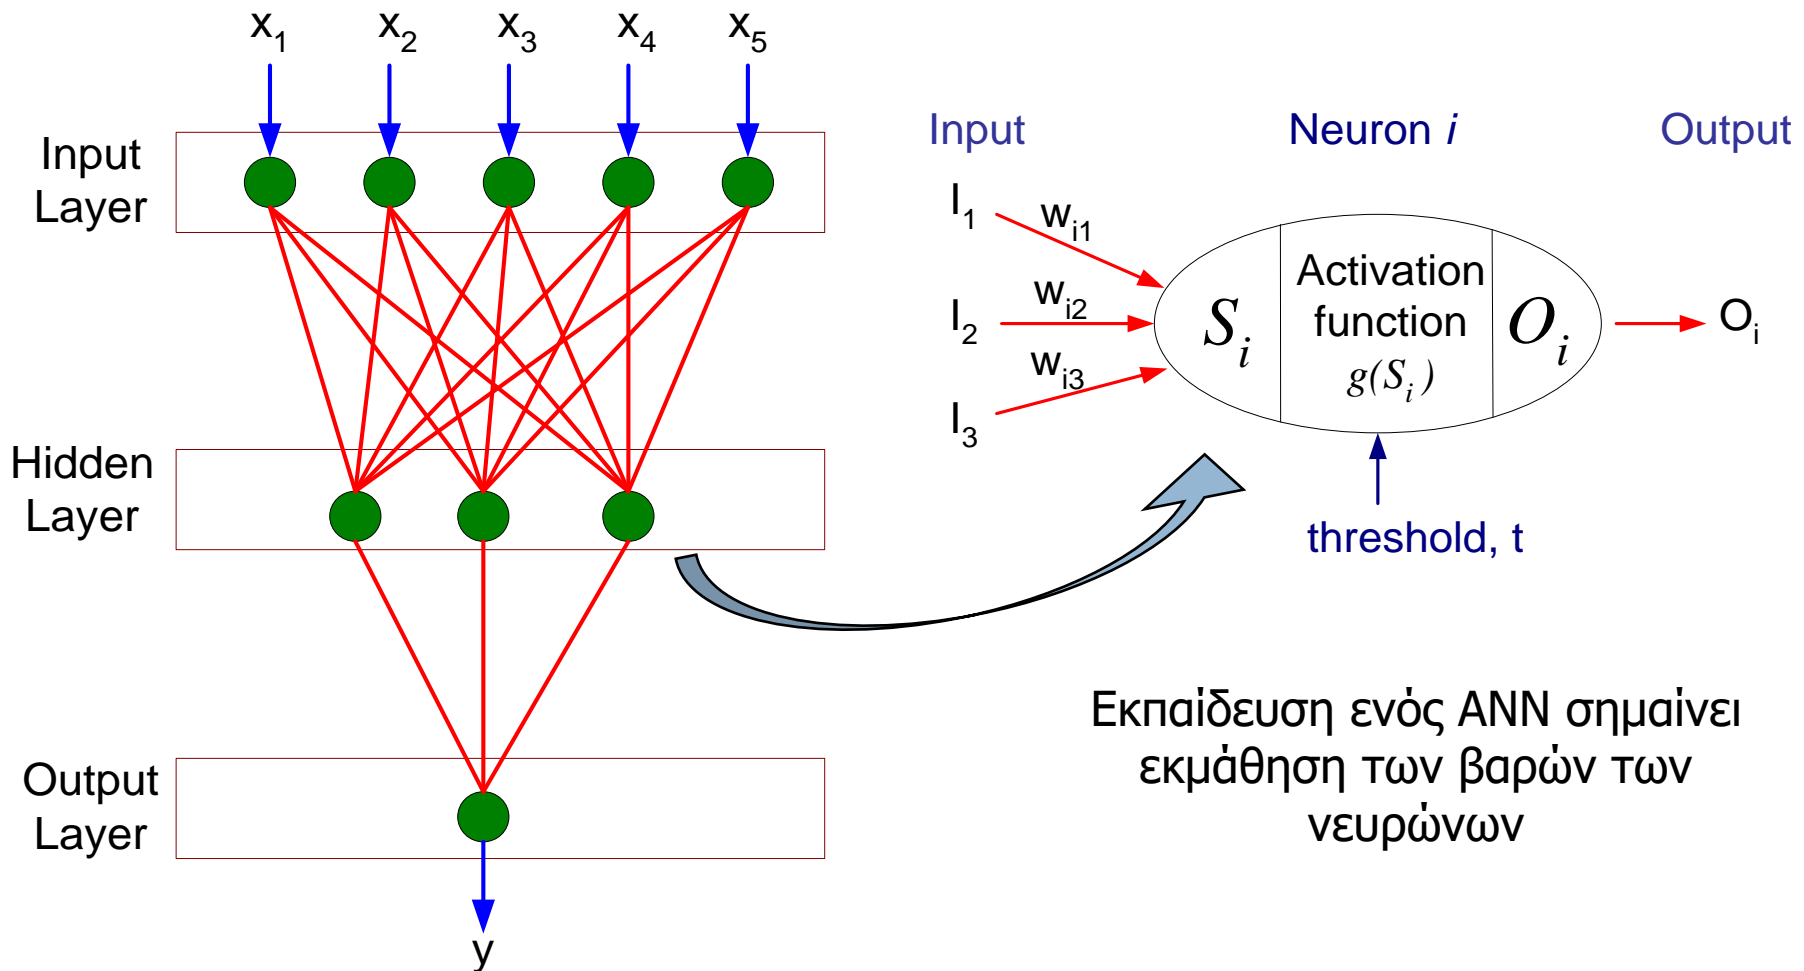
Μη γραμμικά διαχωρίσιμο

- Το Perceptron μπορεί να αναπαραστήσει μερικές πολύ χρήσιμες συναρτήσεις (π.χ.  $\text{AND}(x_1, x_2)$ )
- Συναρτήσεις που δεν είναι γραμμικά διαχωρίσιμες (π.χ.  $\text{XOR}(x_1, x_2)$ ) δεν μπορούν να αναπαρασταθούν

# Τμηματοποίηση του υπερεπιπέδου

- Ένα επιπλέον επίπεδο μοντελοποιεί κυρτά τμήματα
  - “Μια περιοχή χωρίς «βαθουλώματα»”
  - Το Perceptron μοντελοποιεί, αλλά δεν μπορεί να μάθει
  - Μια Sigmoid συνάρτηση μαθαίνει κυρτά τμήματα
  - Δυο επίπεδα συναθροίζουν κυρτά τμήματα
- Στη θεωρία, τα περισσότερα επίπεδα δεν προσθέτουν κάτι
- Στην πράξη, τα περισσότερα επίπεδα προσθέτουν!

# Γενική δομή ενός ANN

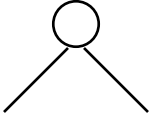
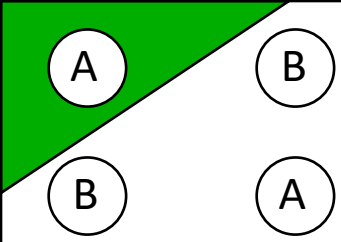
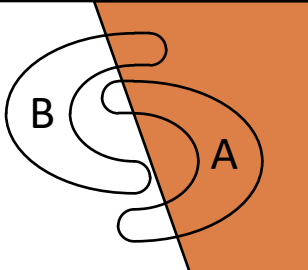
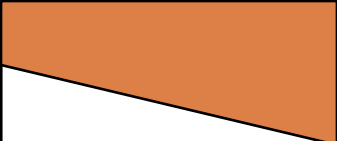
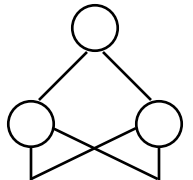
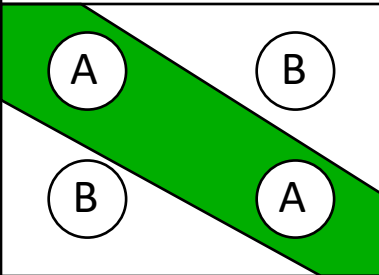
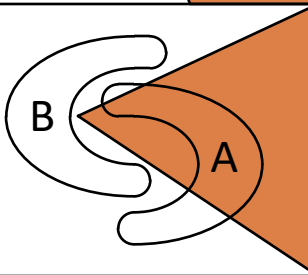
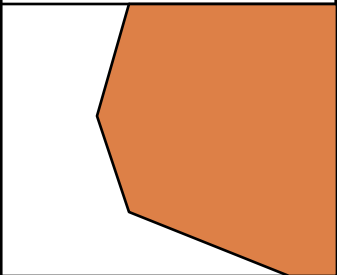
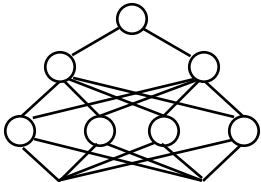
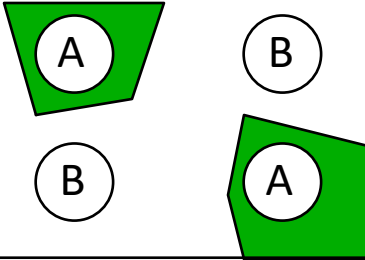
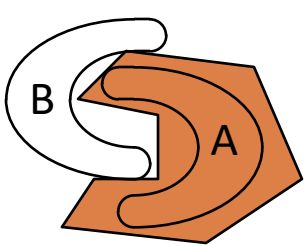
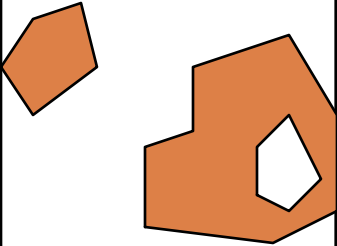


# Τυπικές συναρτήσεις ενεργοποίησης

- Αυστηρού κατωφλίου (σύμφωνα με το βιολογικό παράδειγμα)
  - Είτε ενεργοποιείται είτε όχι
- Sigmoid συναρτήσεις ('S'-shaped καμπύλες)
  - Η logistic συνάρτηση
  - Η υπερβολική εφαπτομένη (συμμετρική)
    - Και οι δυο έχουν απλές διαφορικές
    - Μόνο το σχήμα μετράει

$$f(x) = \frac{1}{1 + e^{-ax}}$$

# Διάφοροι τύποι μη γραμμικών προβλημάτων

Δομή	Τύποι περιοχών αποφάσεων	Exclusive-OR πρόβλημα	Κλάσεις με μικτές περιοχές	Πιο γενικά σχήματα περιοχών
<p>Single-Layer</p> 	<p>Half Plane Bounded By Hyperplane</p>			
<p>Two-Layer</p> 	<p>Convex Open Or Closed Regions</p>			
<p>Three-Layer</p> 	<p>Arbitrary (Complexity Limited by No. of Nodes)</p>			

# Perceptrons

- Εκπαίδευση σε προβλήματα 2 κλάσεων
- Μέθοδος Ελαχίστων Τετραγώνων
- Προβλήματα πολλαπλών κλάσεων

# Εκπαίδευση Perceptron

- Θεωρήστε ότι δημιουργείτε διανύσματα που προκύπτουν από δυο κλάσεις  $C_1$  and  $C_2$ , έστω:
  - $x_1(1), x_1(2), x_1(3), \dots$  ανήκουν στο  $C_1$ , και
  - $x_2(1), x_2(2), x_2(3), \dots$  ανήκουν στο  $C_2$
- Επίσης, θεωρήστε ότι επανορίζουμε τα διανύσματα  $\mathbf{x}(n)$  και  $\mathbf{w}(n)$  ώστε να συμπεριλαμβάνουν μια πόλωση (bias), έστω:
  - $\mathbf{x}(n) = [+1, x_1(n), \dots, x_m(n)]^T$ ; και
  - $\mathbf{w}(n) = [b(n), w_1(n), \dots, w_m(n)]^T \quad \mathbf{x}, \mathbf{w} \in \mathbb{R}^m$



# Εκπαίδευση Perceptron (συν.)

- Τότε θα πρέπει να υπάρχει ένα διάνυσμα βαρών  $\mathbf{w}$  τέτοιο ώστε:
  - $\mathbf{w}^T \mathbf{x} > 0$ , όταν το  $\mathbf{x}$  ανήκει στην κλάση  $C_1$ ; και
  - $\mathbf{w}^T \mathbf{x} \leq 0$ , όταν το  $\mathbf{x}$  ανήκει στην κλάση  $C_2$ ;
- Επιλέγουμε αυθαίρετα σε ποια κλάση ανήκει το  $\mathbf{w}^T \mathbf{x} = 0$  (έστω στην κλάση  $C_2$ )
- Ο αλγόριθμος εκπαίδευσης των βαρών του perceptron μπορεί να οριστεί ως εξής:

# Εκπαίδευση Perceptron (συν.)

1. Εάν το  $n^{\text{th}}$  στοιχείο του σετ εκπαίδευσης,  $\mathbf{x}(n)$  είναι σωστά ταξινομημένο από το τρέχον σετ βαρών, το  $\mathbf{w}(n)$  δεν χρειάζεται διόρθωση. Ισχύει δηλαδή:
  - $\mathbf{w}(n+1)=\mathbf{w}(n)$ ,  
εάν  $\mathbf{w}^T \mathbf{x}(n) > 0$  και το  $\mathbf{x}(n)$  ανήκει στην κλάση  $C_1$ ;
  - $\mathbf{w}(n+1)=\mathbf{w}(n)$ ,  
εάν  $\mathbf{w}^T \mathbf{x}(n) \leq 0$  και το  $\mathbf{x}(n)$  ανήκει στην κλάση  $C_2$ ;

# Εκπαίδευση Perceptron (συν.)

2. Αλλιώς, το διάνυσμα βαρών προσαρμόζεται σύμφωνα με τον παρακάτω κανόνα:
  - $\mathbf{w}(n+1) = \mathbf{w}(n) - \eta(n)\mathbf{x}(n)$ ,  
εάν  $\mathbf{w}^T\mathbf{x}(n) > 0$  και  $\mathbf{x}(n)$  ανήκει στην κλάση  $C_2$ ;
  - $\mathbf{w}(n+1) = \mathbf{w}(n) + \eta(n)\mathbf{x}(n)$ ,  
εάν  $\mathbf{w}^T\mathbf{x}(n) \leq 0$  και  $\mathbf{x}(n)$  ανήκει στην κλάση  $C_1$ ;
  - Η παράμετρος  $\eta(n)$  ονομάζεται *ρυθμός εκπαίδευσης (learning rate)* και ελέγχει το ποσοτό προσαρμογής του διανύσματος βαρών κατά την  $n$  επανάληψη.

# Εκπαίδευση Perceptron (συν.)

- Εάν θεωρήσουμε ότι η *επιθυμητή απόκριση* (desired response) δίνεται από:

$$d(n) = \begin{cases} +1 & \text{if } x(n) \text{ belongs to class } C_1 \\ -1 & \text{if } x(n) \text{ belongs to class } C_2 \end{cases}$$

τότε μπορούμε να ξαναγράψουμε τον κανόνα προσαρμογής (εκπαίδευσης) στη μορφή ενός κανόνα *διόρθωσης σφάλματος* (error-correction):

- $\mathbf{w}(n+1) = \mathbf{w}(n) + \eta [d(n) - y(n)] \mathbf{x}(n)$

όπου  $e(n) = \eta [d(n) - y(n)]$  είναι το *σήμα σφάλματος*

- Ο ρυθμός εκπαίδευσης είναι μια θετική σταθερά στο  $0 < \eta \leq 1$ .

# Εκπαίδευση Perceptron (συν.)

- Όταν δίνουμε τιμή στο  $\eta$  μέσα στο εύρος  $(0,1]$  πρέπει να έχουμε στο μυαλό μας δυο αντικρουόμενες απαιτήσεις:
  - Η συνάθροιση (*Averaging*) των προηγούμενων εισόδων, η οποία οδηγεί και σε σταθερές εκτιμήσεις βαρών, απαιτεί μικρή τιμή για το  $\eta$
  - Η γρήγορη σύγκλιση (*Fast adaptation*) σε σχέση με τις πραγματικές αλλαγές στις κατανομές της διαδικασίας που είναι υπεύθυνη για τη δημιουργία του διανύσματος εισόδου  $\mathbf{x}$ , απαιτεί μεγάλη τιμή για το  $\eta$

# Εκπαίδευση με τη μέθοδο Ελαχίστων τετραγώνων (LSF)

- Εάν οι κλάσεις είναι γραμμικά διαχωρίσιμες, τότε το perceptron δίνει έξοδο  $\pm 1$
- Εάν οι κλάσεις είναι **ΔΕΝ** γραμμικά διαχωρίσιμες, τότε πρέπει να υπολογίσουμε τα βάρη  $w_1, w_2, \dots, w_0$  ώστε η διαφορά ανάμεσα:
  - Στην πραγματική έξοδο του ταξινομητή  $w^T x$  και
  - Τις επιθυμητές εξόδους, π.χ.
 
$$+1, \text{ αν } x \in \omega_1$$

$$-1, \text{ αν } x \in \omega_2$$

να είναι όσο το δυνατόν **ΜΙΚΡΟΤΕΡΗ**.

# Εκπαίδευση με τη μέθοδο Ελαχίστων τετραγώνων (LSF) - II

- **ΜΙΚΡΗ**, ως προς τη λογική του μέσου τετραγωνικού σφάλματος, σημαίνει επιλογή κατάλληλου, ώστε η συνάρτηση κόστους:
  - $J(w) \equiv E[(y - w^T x)^2]$  γίνεται ελάχιστη
  - $\hat{w} = \arg \min_w J(w)$
  - $y$  είναι η αντίστοιχη επιθυμητή απόκριση

# Εκπαίδευση με τη μέθοδο Ελαχίστων τετραγώνων (LSF) - III

- Ελαχιστοποίηση του

$J(w)$  ως προς  $w$ :

$$\frac{\partial J(w)}{\partial w} = \frac{\partial}{\partial w} E[(y - w^T x)^2] = 0 = 2E[x(y - x^T w)] \Rightarrow$$

$$E[xx^T]w = E[xy] \Rightarrow \hat{w} = R_x^{-1} E[xy]$$

- Όπου  $R_x$  είναι ο πίνακας αυτοσυσχέτισης

$$R_x \equiv E[xx^T] = \begin{bmatrix} E[x_1x_1] & E[x_1x_2] \dots & E[x_1x_l] \\ \dots & \dots & \dots \\ E[x_lx_1] & E[x_lx_2] \dots & E[x_lx_l] \end{bmatrix}$$

- και  $E[xy] = \begin{bmatrix} E[x_1y] \\ \dots \\ E[x_ly] \end{bmatrix}$  το διάνυσμα ετεροσυσχέτισης (crosscorrelation)



# Γενίκευση για προβλήματα πολλαπλών κλάσεων

- Στόχος είναι ο υπολογισμός  $M$  γραμμικών συναρτήσεων διαχωρισμού:  $g_i(x) = w_i^T x$   
σύμφωνα με το MSE.
- Υιοθετήστε ως επιθυμητές αποκρίσεις  $y_i$ :  

$$y_i = 1 \quad \text{if } \underline{x} \in c_i$$

$$y_i = 0 \quad \text{otherwise}$$
- Έστω:  $y = [y_1, y_2, \dots, y_M]^T$
- Και ο πίνακας:  $W = [w_1, w_2, \dots, w_M]$

# Γενίκευση για προβλήματα πολλαπλών κλάσεων

- Στόχος είναι ο υπολογισμός του  $W$ :  

$$\hat{W} = \arg \min_W E[\|y - W^T x\|^2] = \arg \min_W E \left[ \sum_{i=1}^M (y_i - w_i^T \cdot x)^2 \right]$$
- Το παραπάνω είναι ισοδύναμο με έναν αριθμό  $M$  από MSE προβλήματα ελαχιστοποίησης.
- Μεθοδολογία:
  - Σχεδιάστε κάθε  $w_i$  ώστε η επιθυμητή έξοδος είναι 1 για  $x \in c_i$  και 0 για κάθε άλλη κλάση
  - Σημείωση: Το κριτήριο MSE ανήκει σε μια πιο γενική ομάδα συναρτήσεων κόστους με την εξής βασική ιδιότητα:
    - Η τιμή του  $g_i(x)$  είναι εκτίμηση, με τη λογική του MSE, της  $P(c_i | x)$  εκ των υστέρων πιθανότητας, δεδομένου ότι οι επιθυμητές έξοδοι που χρησιμοποιούνται κατά τη διάρκεια της εκπαίδευσης είναι  $y_i = 1, x \in c_i$  και 0 διαφορετικά.

# Πηγές

- Introduction to Data Mining, Tan, Steinbach, Kumar.
- Pattern recognition, Theodoridis & Koutroumbas.